

단일 레이어를 넘어서: Grad-CAM 기반 객체 위치 추정에서 레이어 결합, 체크포인트 선택, Threshold 민감도에 대한 실증 연구

장주희

Abstract

Grad-CAM은 합성곱 신경망이 분류 결정을 내릴 때 이미지의 어느 영역에 주목하는지 시각화하는 대표적인 방법이며, 생성된 히트맵을 바운딩 박스로 변환하면 약지도(weakly-supervised) 객체 위치 추정 기법으로도 활용할 수 있다. 그러나 기존 실험들은 단일 레이어, 단일 체크포인트, 단일 threshold를 고정한 채 진행되는 경우가 많아, 이러한 선택들이 실제로 이 과제에 적합한지는 명확하지 않다. 본 연구는 Grad-CAM 기반 위치 추정을 위해 미세조정된 ResNet50 분류기를 대상으로, 각 설계 선택을 하나씩 분리해 측정하는 네 단계의 순차 실험을 수행하였으며, 성능은 정답 바운딩 박스와의 IoU(Intersection over Union)로 평가하였다. 그 결과 (1) layer1~4의 Grad-CAM을 단순 평균 또는 깊이 가중합으로 결합하는 방식은 threshold를 최적화한 조건에서도 최상의 단일 레이어 성능을 넘어서지 못하였고, (2) validation accuracy가 가장 높은 체크포인트를 선택하는 것이 오히려 일반적인 최종 epoch 모델보다 낮은 위치 추정 IoU를 보였으며, (3) 세 요소 중 threshold가 IoU에 가장 큰 영향을 미쳐, 관행적으로 사용되는 threshold=0.5는 threshold=0.1(평균 IoU 0.4538)에 비해 현저히 낮은 성능(0.0264)을 보였다. threshold를 최적화한 조건에서의 최종 종합 비교에서는 단일 중간 깊이 레이어(layer3)가 두 결합 방식은 물론 관행적으로 사용되는 마지막 레이어(layer4)보다도 우수한 성능을 기록하였다. 이러한 결과는 CAM/Grad-CAM 기반 위치 추정 방법을 평가할 때 threshold 설정이 레이어 선택 못지않게, 혹은 그 이상으로 중요하게 다루어져야 함을 시사한다.

1 서론

기존 Grad-CAM 기반 객체 위치 추정 실험에서는 특정 단일 레이어의 Grad-CAM을 사용하여 객체 위치를 추정하는 경우가 많다. 그러나 하나의 레이어만 사용할 경우 해당 레이어가 가진 특징 정보에만 의존하게 되어, 다양한 수준의 특징 정보를 충분히 활용하지 못할 가능성이 있다. 이는 자연스럽게 다음 질문으로 이어진다: 여러 레이어의 Grad-CAM을 결합하면 단일 레이어의 한계를 보완하고 객체 위치 추정 성능을 향상시킬 수 있는가?

레이어 선택 외에도, 어떤 학습 체크포인트를 사용할지와 히트맵을 바운딩 박스로 변환할 때 어떤 threshold를 적용할지 역시 충분한 실증적 근거 없이 관행적으로 결정되는 경우가 많다. validation accuracy 기준으로 선택한 체크포인트가 더 나은 위치 추정기이기도 한지, 그리고 관행적으로 사용되는 threshold=0.5가 실제로 이 과제에 적합한지는 명확하지 않다.

이러한 질문에 답하기 위해, 본 연구는 바운딩 박스 주석이 있는 견종 데이터셋으로 미세조정된 ResNet50 분류기를 대상으로 네 단계의 순차 실험을 설계하고, 각 실험이 하나의 요인만을 분리해서 검증하도록 하였다. (1) layer1~4의 Grad-CAM을 단순 평균과 깊이 가중합 두 가지 방식으로 결합하여 IoU를 비교하고, (2) 동일한 결합 방식을 최종 epoch의 일반 모델과 validation accuracy가 가장 높은 체크포인트 모델에 각각 적용하여 비교하며, (3) 관행적인 threshold=0.5가 실제로 최선인지 확인하기 위해 threshold를 0.1부터 0.9까지 조정해가며 성능을 측정하고, (4) 이렇게 실증적으로 찾아낸 최적 threshold 조건에서 모든 단일 레이어와 두 결합 방식을 종합적으로 비교하였다. 특정 이미지 한 장의 우연한 결과에 좌우되지 않도록, 네 실험 모두 고정된 20장의 이미지 표본에 대해 평가하였다.

실험 결과, 레이어 결합, 정확도 기반 체크포인트 선택, 관행적 threshold라는 직관적으로 그럴듯한 세 가지 전략 중 어느 것도 위치 추정 성능을 안정적으로 향상시키지 못하였다. 특히 threshold 선택은 매우 큰 영향을 미쳤으며, threshold를 최적화한 조건에서는 결국 잘 선택된 단일 레이어 하나가 두 결합 전략 모두를 능가하였다.

2 관련 연구

Class Activation Mapping(CAM) [1]은 마지막 컨볼루션 특징 맵을 완전연결(FC) 분류 가중치로 선형 결합하는 방식이지만, 마지막 FC 레이어 직전에 GAP(Global Average Pooling) 레이어가 존재하는 구조를 전제로 한다. Grad-CAM [2]은 이를 일반화하여, 각 특징 맵 채널을 대상 클래스 점수에 대한 gradient의 전역 평균으로 가중함으로써 GAP+FC라는 구조적 제약을 제거하고, 임의의 컨볼루션 레이어에서 히트맵을 추출할 수 있도록 하였다. 두 방법 모두 해석 가능성뿐 아니라 약지도 위치 추정 신호로도 활용되어 왔으며, 정답 바운딩 박스와의 IoU로 평가되어 왔다.

3 실험 1: 레이어 결합 — 평균 vs. 가중합

단일 Grad-CAM 레이어는 하나의 추상화 수준만을 포착한다. layer1부터 layer4까지의 Grad-CAM을 결합하면, 얇은 레이어의 세밀한 공간 정보와 깊은 레이어의 의미 정보를 함께 활용하여 이러한 한계를 보완할 수 있으리라는 가설을 세웠다. 두 가지 결합 방식을 실험하였다: (a) 4개 레이어에 동일한 비중(각 0.25)을 부여하는 단순 평균, (b) 깊은 레이어일수록 더 큰 비중을 부여하는 깊이 가중합(layer1=0.1, layer2=0.2, layer3=0.3, layer4=0.4). 20장의 이미지에 대해 threshold 0.1~0.9 전 구간에서 평가하였다.

Table 1: Threshold 구간별 평균 결합 vs. 가중합 결합 (20장 평균)

Threshold 구간	평균 결합	가중합 결합	우세
0.1~0.8	전 구간 우세	전 구간 열세	평균 결합
0.3 (최고점)	0.6455	0.6239	평균 결합
0.9	열세	우세	가중합 결합
9개 threshold 전체 평균	0.4765	0.4605	평균 결합




Figure 1: Threshold 0.1~0.9 구간에서 평균 결합과 가중합 결합의 평균 IoU 비교

거의 전 구간(0.1~0.8)에서 단순 평균이 깊이 가중합보다 우수했으며, 전체 평균 IoU 역시 0.4765 vs. 0.4605로 평균 결합이 앞섰다. 이는 더 깊고 의미론적으로 풍부한 레이어에 더 큰 비중을 두어야 한다는 직관과 반대되는 결과로, 본 실험 조건에서는 모든 레이어를 동일하게 취급하는 편이 오히려 더 안정적이었다.

4 실험 2: 체크포인트 선택의 영향

실험 1은 다른 체크포인트를 사용했을 때의 차이를 확인하지 않은 채 최종 epoch 모델만을 사용하였다. 여기서는 이 “일반” 최종 epoch 모델과, 학습 과정 중 validation accuracy가 가장 높았던 체크포인트(epoch 5, validation accuracy 67.63%)를 비교하였으며, 실험 1과 동일한 평균/가중합 결합 절차를 두 모델 모두에 적용하였다.

Table 2: 일반(최종 epoch) 모델 vs. Best-validation-accuracy 체크포인트

모델	평균 결합 IoU	가중합 결합 IoU
일반 모델 (최종 epoch)	0.4765	0.4605
Best-val-accuracy 체크포인트	0.4084	0.3182
차이 (체크포인트 – 일반)	-0.0681	-0.1423




Figure 2: 일반 모델과 best-validation-accuracy 체크포인트 모델의 IoU 비교

validation accuracy가 더 높은 분류기가 더 나은 위치 추정기이기도 할 것이라는 가정과 달리, best 체크포인트 모델은 두 결합 방식 모두에서 더 낮은 성능을 보였으며, 특히 가중합 결합에서 그 하락 폭(-0.1423)이 두드러졌다. 이는 분류 성능과 위치 추정 성능이 동일 아키텍처의 학습 과정 내에서도 신뢰할 만하게 결합되어 있지 않을 수 있음을 보여준다.

5 실험 3: Threshold 민감도

지금까지의 모든 실험은 관행적인 threshold 값인 0.5를 사용하였다. threshold는 추출되는 영역의 크기와 형태를 직접 결정하므로, 지금까지 정량화되지 않은 상당한 영향을 IoU에 미칠 수 있다고 가정하였다. 모델과 레이어(layer2)를 고정한 상태에서, 동일한 20장의 이미지에 대해 threshold를 0.1부터 0.9까지 조정하며 측정하였다.

Table 3: Threshold에 따른 평균 IoU 변화 (layer2, 20장)

Threshold	평균 IoU
0.1	0.4538 (최고)
0.5 (관행적 기본값)	0.0264
차이 (0.1 - 0.5)	+0.4274




Figure 3: Threshold가 증가함에 따라 평균 IoU가 단조 감소하는 양상

threshold가 높아질수록 평균 IoU는 단조적으로 감소하였으며, 관행적으로 사용되는 threshold=0.5의 성능(0.0264)은 실험 범위 내 가장 낮은 threshold인 0.1의 성능(0.4538)에 비해 현저히 낮았다(차이 +0.4274). 이 차이는 실험 1에서 관찰된 결합 방식 간 차이(약 0.016)나 실험 2에서 관찰된 체크포인트 간 차이(약 0.07~0.14)보다 한 자릿수 이상 크다. 이는 threshold가 사소한 구현 세부사항이 아니라 Grad-CAM 위치 추정 성능을 좌우하는 1차적 요인임을 시사한다.

6 실험 4: 최적 Threshold에서의 최종 종합 비교

실험 3에서 확인한 threshold의 큰 영향력을 고려하여, 실증적으로 찾아낸 최적 threshold인 0.1을 사용하여 4개의 단일 레이어와 2개의 결합 방식 전체를 동일한 모델과 이미지에 대해 다시 비교하였다.

Table 4: Threshold=0.1에서 단일 레이어와 결합 방식의 종합 비교

순위	방법	평균 IoU (threshold=0.1)
1	Single layer3	0.6297
2	Layer1~4 가중합	0.5873
3	Layer1~4 평균	0.5610
4	Single layer4	0.5514
5	Single layer2	0.4430
6	Single layer1	0.2691

최적 threshold 조건에서는 단일 layer3가 가장 높은 평균 IoU(0.6297)를 기록하여, 가중합 결합(0.5873)과 평균 결합(0.5610)을 모두 앞섰으며, 관행적으로 사용되는 layer4보다도 상당한 차이로 우수하였다(0.6297 vs. 0.5514, +0.0783). 이는 실험 1의 출발 가설, 즉 여러 레이어를 결합하면 성능이 향상될 것이라는




Figure 4: Threshold=0.1에서 단일 레이어와 결합 방식의 정성적 비교 예시

가정을 직접적으로 반박하는 결과이다: threshold를 적절히 조정한 조건에서는 여러 레이어를 결합하는 것이 가장 우수한 단일 레이어를 넘어서지 못하였다. 다만 layer3가 모든 개별 이미지에서 항상 최고 성능을 보인 것은 아니었으며, layer3는 본 데이터셋과 모델 조건에서 평균적으로 가장 우수한 레이어로 해석하는 것이 적절하다.

7 논의

네 실험에 걸쳐 살펴본 세 요소, 즉 레이어 결합 방식, 체크포인트 선택, 이진화 threshold는 위치 추정 IoU에 서로 매우 다른 크기의 영향을 미쳤다. threshold의 영향(threshold 0.1과 0.5 사이 약 0.43)이 압도적으로 컸으며, 이는 결합 방식에 따른 차이(약 0.02)나 체크포인트에 따른 차이(약 0.07~0.14)보다 한 자릿수 이상 큰 수치이다. 이는 Grad-CAM 기반 위치 추정 방법을 평가하거나 비교할 때는 threshold를 0.5와 같은 관행적 값으로 고정하기보다, 실험 프로토콜의 일부로서 threshold를 스윙하고 그 결과를 함께 보고해야 한다는 실질적 시사점으로 이어진다.

또한 두 가지 결과는 일반적인 직관과 배치된다. 첫째, 여러 레이어의 정보를 결합하는 것은, threshold를 최적화한 조건에서 가장 우수한 단일 레이어의 성능을 넘어서지 못하였다. 서로 원래 해상도가 크게 다른 히트맵을 리사이즈하여 섞는 과정이, 가장 우수한 개별 레이어가 가진 더 날카로운 신호를 오히려 희석시켰을 가능성이 있다. 둘째, validation accuracy로 체크포인트를 선택하는 것이 더 나은 위치 추정 성능으로 이어지지 않았고 오히려 더 나쁜 결과를 낳았으며, 이는 분류 정확도와 위치 추정 품질이 학습된 모델의 적어도 부분적으로는 서로 다른 속성에 의해 좌우된다는 것을 보여준다.

본 연구의 결론은 고정된 20장의 이미지 표본에 대해 평가한 단일 ResNet50 모델의 결과에 기반한다. 초기에 이미지 1장만으로 진행했던 예비 실험에서는 재현되지 않는 패턴이 관찰되었으나, 20장으로 표본을 확장하자 이 패턴은 사라졌다. 이는 Grad-CAM 비교 시 충분한 크기의 표본으로 평가해야 할 필요성을 보여준다. 왜 layer3가 이 데이터셋에서 최적이었는지는 추측의 영역으로 남아있으며, 다른 세밀 분류 데이터셋에서 검증하는 것은 향후 연구 과제로 남긴다.

8 결론

본 연구는 Grad-CAM 기반 약지도 객체 위치 추정에서 흔히 이루어지지만 실증적으로 검증되는 경우는 드문 세 가지 설계 선택, 즉 어떤 레이어(들)을 사용할지, 어떤 학습 체크포인트를 사용할지, 어떤 이진화 threshold를 적용할지를 살펴보았다. 네 단계의 순차 실험을 통해, 여러 레이어를 결합하는 것과 validation accuracy가 가장 높은 체크포인트를 선택하는 것 모두 위치 추정 IoU를 안정적으로 향상시키지 못한 반면, 이진화 threshold는 그동안 충분히 검토되지 않았던 훨씬 큰 영향을 미친다는 것을 확인하였다. threshold를 최적화한 조건에서는 단일 중간 깊이 레이어(layer3)가 두 가지 다중 레이어 결합 전략과 관행적으로 사용되는 마지막 레이어를 모두 능가하였다. 이상의 결과를 바탕으로, Grad-CAM 기반 위치 추정 방법을 평가할 때는 threshold 선택에 대해 레이어 선택 못지않은 실증적 주의를 기울여야 하며, 레이어 결합이나 정확도 기반 체크포인트 선택이 위치 추정 성능을 향상시킬 것이라고 검증 없이 가정해서는 안 된다는 결론을 제시한다.

References

- [1] B. Zhou, A. Khosla, A. Lapedriza, A. Oliva, and A. Torralba. Learning Deep Features for Discriminative Localization. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016.
- [2] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra. Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. In Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017.